

Cycle Gan

투빅스 18 기 김성우

Abstract

Image to Image Translation 은 보통 pair-image 학습.

Image to Image 란?

이미지 인풋을 받고 이미지 아웃풋을 내는 알고리즘을 말한다. 뭐 색깔을 입힌다던지, 낮을 밤으로 바꾼다던지 이런 알고리즘. Paired 또는 unpaired 데이터셋이 있는데 각각 pix2pix 와 cyclegan 이 대표한다.

하지만 이런 pair image 데이터가 많지 않아서 우리는 X 도메인과 Y 도메인 데이터셋 자체를 이용한 cycle gan 을 냈다.

Translation 을 진행하기 위해 loss 을 정방향과 역방향으로 정했다. Cycle consistency loss 을 정의했고 그래서 cycle gan 이라 불렀다.

즉, cyclegan 은 특징이 다른 두 도메인의 데이터만 가지고 온전하게 변환하는 법을 배운다.

이때 \hat{y} 이 Y 에 속하게끔만 만들게 하면 mode collapse 가 일어날 것이다. 하긴 그렇긴 하지. 이것을 해결하기 위해 주기적 일관성을 도입. 주기적 일관성이란 x 를 겨울 이미지 \hat{y} 으로 변환했다면, 그 \hat{y} 을 역변환할

경우 여름 이미지 x 가 되게끔 하는 것. 이렇게 해야 일방적인 mode collapse, Y 만을 만족하는 easy model 이 되지 않는다.

1. $G : x \rightarrow y$ 의 적대적 학습(Adversarial loss)

- 일반 GAN과 동일.

2. $F : y \rightarrow x$ 의 적대적 학습(Adversarial loss)

- 역방향 학습도 추가

3. $x \approx F(G(x))$ 의 주기적 일관성 학습(Cycle consistence loss)

정방향 역방향 모두 일반적인 GAN loss 적용한다.

Cycle consistency loss 은 아래와 같은 function 을 쓴다.

$$\mathcal{L}_{\text{cyc}}(G, F) = \mathbb{E}_{x \sim p_{\text{data}}(x)} [\|F(G(x)) - x\|_1] \\ + \mathbb{E}_{y \sim p_{\text{data}}(y)} [\|G(F(y)) - y\|_1].$$

그래서 총 loss function 은 아래와 같다.

$$\mathcal{L}(G, F, D_X, D_Y) = \mathcal{L}_{\text{GAN}}(G, D_Y, X, Y) \\ + \mathcal{L}_{\text{GAN}}(F, D_X, Y, X) \\ + \lambda \mathcal{L}_{\text{cyc}}(G, F),$$

오 이거 아래 2 번이 특히 괜찮다.

또한 이전 GAN 모델들과 다르게 안정적인 모델 학습을 위해 아래의 2 가지 변경을 가미했다. 먼저 loss function 은 negative loss likelihood 대신에 least-squared loss 으로 변경을 했고 또한 Discriminator 에 mini-batch 의 개념을 이용해 50 개를 한꺼번에 분류하게 만들었다.

평가 지표로는 3 가지가 있으며 각각 Human study 정성적, FCN Score 정량적, per pixel accuracy 이었다. 결과는 아래와 같다.

Loss	Map → Photo	Photo → Map
	% Turkers labeled <i>real</i>	% Turkers labeled <i>real</i>
CoGAN [32]	0.6% ± 0.5%	0.9% ± 0.5%
BiGAN/ALI [9, 7]	2.1% ± 1.0%	1.9% ± 0.9%
SimGAN [46]	0.7% ± 0.5%	2.6% ± 1.1%
Feature loss + GAN	1.2% ± 0.6%	0.3% ± 0.2%
CycleGAN (ours)	26.8% ± 2.8%	23.2% ± 3.4%

Table 1: AMT “real vs fake” test on maps↔aerial photos at 256×256 resolution.

Loss	Per-pixel acc.	Per-class acc.	Class IOU
CoGAN [32]	0.40	0.10	0.06
BiGAN/ALI [9, 7]	0.19	0.06	0.02
SimGAN [46]	0.20	0.10	0.04
Feature loss + GAN	0.06	0.04	0.01
CycleGAN (ours)	0.52	0.17	0.11
pix2pix [22]	0.71	0.25	0.18

Table 2: FCN-scores for different methods, evaluated on Cityscapes labels→photo.

Loss	Per-pixel acc.	Per-class acc.	Class IOU
CoGAN [32]	0.45	0.11	0.08
BiGAN/ALI [9, 7]	0.41	0.13	0.07
SimGAN [46]	0.47	0.11	0.07
Feature loss + GAN	0.50	0.10	0.06
CycleGAN (ours)	0.58	0.22	0.16
pix2pix [22]	0.85	0.40	0.32

Table 3: Classification performance of photo→labels for different methods on cityscapes.

Loss	Per-pixel acc.	Per-class acc.	Class IOU
Cycle alone	0.22	0.07	0.02
GAN alone	0.51	0.11	0.08
GAN + forward cycle	0.55	0.18	0.12
GAN + backward cycle	0.39	0.14	0.06
CycleGAN (ours)	0.52	0.17	0.11

Table 4: Ablation study: FCN-scores for different variants of our method, evaluated on Cityscapes labels→photo.

Loss	Per-pixel acc.	Per-class acc.	Class IOU
Cycle alone	0.10	0.05	0.02
GAN alone	0.53	0.11	0.07
GAN + forward cycle	0.49	0.11	0.07
GAN + backward cycle	0.01	0.06	0.01
CycleGAN (ours)	0.58	0.22	0.16

Table 5: Ablation study: classification performance of photo→labels for different losses, evaluated on Cityscapes.

이러한 Cycle Gan 의 한계점으로는 제한적인 변경만 가능하다는 점과 Y 에 대한 이미지가 부족하면 학습이 안된다는 점으로 들었다.

요약 .

Cycle Gan 은 cycle consistency loss 에서 이름을 따왔다. 이 GAN 모델은 image to image 을 paired image 활용하지 않고 오직 독립적인 집단 X 와 Y 의 특징을 이용해 학습을 한다. X 에서 Y 로 변환하는 GAN 을 기본으로다가 Y 에서 X 로 변환하는 GAN 을 활용해 mode collapse 을 방지해 이름하여 cycle circulation 만들었다.